



Институт
интеллектуальных кибернетических систем

Кафедра кибернетики (№ 22)

Направление подготовки 09.03.04 Программная инженерия

Пояснительная записка

к учебно-исследовательской работе студента на тему:

Разработка метода геолокации по серии
изображений на основе глубокого обучения

Группа

Б14-506

Студент

(подпись)

Шедько А.Ю.

(ФИО)

Руководитель

(0-15 баллов)

(подпись)

Трофимов А.Г.

(ФИО)

-

Научный консультант

(0-15 баллов)

(подпись)

(ФИО)

Оценка руководителя _____

Оценка комиссии _____

Члены комиссии



**Факультет Кибернетики и Информационной
безопасности**

Кафедра кибернетики (№ 22)

Направление подготовки 09.04.04 Программная инженерия

Пояснительная записка

к ВКР магистра на тему:

Группа

Студент

(подпись)

(ФИО)

Руководитель

(подпись)

(ФИО)

Научный консультант

(подпись)

(ФИО)

Оценка руководителя _____

Оценка комиссии _____



Институт интеллектуальных кибернетических систем
КАФЕДРА КИБЕРНЕТИКИ

Задание на УИР

Студенту гр. Б14-506
(группа)

Шедько Андрею Юрьевичу
(фио)

ТЕМА УИР

Разработка метода геолокации по серии изображений на основе глубокого обучения

ЗАДАНИЕ

№ п/п	Содержание работы	Форма отчетности	Срок исполнения	Отметка о выполнении Дата, подпись
1.	Аналитическая часть			
1.1.	Обзор методов геолокации по изображениям	Текст ПЗ	18.03.2018	
1.2.	Изучение и сравнительный анализ алгоритмов глубокого обучения с целью выбора подхода к задаче	Текст ПЗ	18.03.2018	
1.3.	Анализ алгоритмов пространственного разбиения поверхности земли для решения задачи классификации	Текст ПЗ	18.03.2018	
1.4.	Анализ существующих решений задачи геолокации по изображениям.	Текст ПЗ	18.03.2018	
1.5.	Анализ возможностей применения подхода transfer learning к проблеме геолокации с помощью глубокого обучения	Текст ПЗ	18.03.2018	
2.	Теоретическая часть			
2.1.	Формальная постановка задачи геолокации по серии изображений	Текст ПЗ	18.03.2018	
2.2.	Выбор/разработка методов оценки точности работы алгоритмов геолокации	Метод	18.03.2018	
2.3.	Модификация существующих решений в области для работы с серией изображений	Алгоритм	18.03.2018	
2.4.	Разработка метода геолокации по серии изображений используя выбранные/разработанные выше алгоритмы/методы	Метод	18.03.2018	
3.	Инженерная часть			
3.1.	Разработать архитектуру для системы (с учетом требований к области применения)	Схемы, Диаграммы	25.03.2018	
3.2.	Проектирование системы геолокации по серии изображений	Схемы, Диаграммы	25.03.2018	
3.3.	Результаты проектирования оформить с помощью диаграмм, схем, описаний. При проектировании использовать язык UML	Схемы, Диаграммы	25.03.2018	
4.	Технологическая и практическая часть			
4.1.	Реализовать разработанные алгоритмы	Исполняемые файлы, исходный текст	25.03.2018	

4.2.	Протестировать систему с помощью сравнения с аналогами. Разработать тестовые примеры для подтверждения исполнения требований.	Исполняемые файлы, исходные тексты тестов и тестовых примеров	Практика	
4.3.	Реализация должна показывать результат лучше чем аналоги на территории РФ	Графики, Таблицы	Практика	
4.4.	Ожидаемым результатом является программное обеспечение позволяющее осуществлять распознавание континента (2500 km), страны(750 km), города (25 km), где сделано фото	Графики, Таблицы, Исполняемые файлы	Практика	
4.5.	При реализации использовать ЯП python и библиотеки keras, tensorflow	Код программы	25.03.2018	
5.	Оформление пояснительной записки (ПЗ) и иллюстративного материала для доклада.	Текст ПЗ, презентация	25.03.2018	

ЛИТЕРАТУРА

1.	Weyand T., Kostrikov I., Philbin J. Planet-photo geolocation with convolutional neural networks //European Conference on Computer Vision. – Springer, Cham, 2016. – С. 37-55.
2.	Babenko A. et al. Neural codes for image retrieval //European conference on computer vision. – Springer, Cham, 2014. – С. 584-599.
3.	Krizhevsky A., Sutskever I., Hinton G. E. Imagenet classification with deep convolutional neural networks //Advances in neural information processing systems. – 2012. – С. 1097-1105.
4.	Hays J., Efros A. A. IM2GPS: estimating geographic information from a single image //Computer Vision and Pattern Recognition, 2008. CVPR 2008. IEEE Conference on. – IEEE, 2008. – С. 1-8.
5.	Буч Г., Рамбо Д., Джекобсон А. Язык UML. Руководство пользователя: Пер. с англ. М.// ДМК, 2007
6.	Hastie, Trevor, Tibshirani, Robert and Friedman, Jerome. The elements of statistical learning: data mining, inference and prediction – 2 edition – Springer, 2009.
7.	Hays J., Efros A. A. Large-scale image geolocalization //Multimodal Location Estimation of Videos and Images. – Springer, Cham, 2015. – С. 41-62.
8.	Николенко С., Кадури А., Архангельская Е. Глубокое обучение. Погружение в мир нейронных сетей // Питер Спб – 2018 – С. 480, ISBN: 9785496025362
9.	
10.	

Дата выдачи задания:

Руководитель

Трофимов А.Г.

(ФИО)

« ____ » февраля 2018г.

Студент

Шедько А.Ю.

(ФИО)

Реферат

Пояснительная записка содержит XXX страниц (из них XX страниц приложений). Количество использованных источников – XX. Количество приложений – X.

Ключевые слова:

Целью данной работы является ...

В первой главе проводится обзор и анализ ...

Во второй главе описываются использованные и разработанные/модифицированные методы-/модели/алгоритмы

В третьей главе приводится описание программной реализации и экспериментальной проверки

В приложении ?? описаны основные требования к форматированию пояснительных записок к дипломам и (магистерским) диссертациям.

В приложении ?? представлена общая структура пояснительной записки.

В приложении ?? приведены некоторые дополнительные комментарии к использованию данного шаблона.

Содержание

Введение	8
1 Анализ проблематики задачи геолокации по изображениям	9
1.1 Обзор методов геолокации по изображениям	9
1.2 Изучение и сравнительный анализ алгоритмов Выделения признаков изображений с целью выбора подхода к задаче	9
1.2.1 Глобальные дескрипторы	9
1.2.2 Локальные дескрипторы	12
1.2.3 Глубокие сверточные нейросети (ГСНС)	14
1.3 Анализ алгоритмов пространственного разбиения поверхности земли для решения задачи классификации	15
1.4 Существующие решения задачи геолокации по изображениям	15
1.4.1 ПО для работы с алгоритмами глубокого обучения	15
1.5 Анализ возможностей применения подхода transfer learning к проблеме геолокации с помощью глубокого обучения	16
1.6 Выводы	16
1.7 Постановка задачи УИР	17
2 Разработка моделей и алгоритмов ...	18
2.1 Формальная постановка задачи геолокации по серии изображений	18
2.2 Выбор/разработка методов оценки точности работы алгоритмов геолокации	19
2.3 Модификация существующих решений в области для работы с серией изображений	19
2.3.1 Сети LSTM	20
2.3.2 Архитектура Модели	21
2.4 Разработка метода геолокации по серии изображений используя выбранные/разработанные выше алгоритмы/методы	23
2.5 Выводы	23
3 Инженерная часть	24
3.1 Использование методики «такой-то» для проектирования программных систем «такого-то типа»	24

3.2	Проектирование системы геолокации по серии изображений	24
3.3	Архитектура подсистемы генерации признаков	24
3.4	Архитектура подсистемы классификации	24
3.5	Проектирование протокола взаимодействия подсистем классификации и генера- ции признаков	24
3.6	Выводы	24
4	Реализация и экспериментальная проверка ...	25
4.1	Выбор инструментальных средств	25
4.2	Состав и структура реализованного программного обеспечения	25
4.3	Результаты экспериментов	26
4.3.1	Эксперимент с 1 изображением	26
4.3.2	Эксперимент с альбомом	26
4.4	Разработка тестовых примеров	26
4.5	Результаты тестирования и примеры работы системы	27
4.6	Сравнение реализованного программного обеспечения с существующими аналогами	27
4.7	Выводы	27
	Заключение	28

Введение

Задача геолокации по изображениям имеет пользу для народного хозяйства. Актуальность данной работы проявляется в:

- Проблематика данной области интересна в широком круге применений, таких как: поиск расположения определённого объекта, автоматическое отслеживание преступника по фотографии с места происшествия, теоретические исследования алгоритмов глубокого обучения для многоклассовой пространственной классификации. Выиграют от решения этой проблемы специальные службы и корпорации, занимающиеся подобными вещами.
- Задача "Визуальной локализации" [1], поставленная в области компьютерного зрения одной из первых оказалась непростой как для компьютеров, так и для людей. Первой была работа У. Б. Томпсона (Университет Юты) и других [2], основанная на распознавании деталей ландшафта и сопоставлении их с картой местности. Однако при наличии объёмных обучающих выборок ситуация значительно улучшается. Современные работы Т.Вейанда (Google) и И.Кострикова (RWTH Aachen) [3] показывают значительные успехи в данной области. Все предыдущие работы используют значительные объёмы данных и вычислительные мощности, а потому интересна задача решения подобных задач на менее производительном железе, что может быть полезно для развёртывания этой технологии в рамках мобильного приложения.

Новизна работы состоит в использовании для решения задачи современных методов машинного обучения и применения нового обучающего набора.

Суть исследования — описание и разработка алгоритма геолокации на основе набора изображений.

« содержание по главам (по одному абзацу на главу). »

1. Анализ проблематики задачи геолокации по изображениям

1.1 Обзор методов геолокации по изображениям

Задача определения места съемки фотографии довольно не проста из-за неоднозначности и недостаточности информации, содержащейся в одном изображении. Например, типичная пляжная сцена (море, солнце, песок, небо...) может быть заснята почти в любой точке земли. Даже достопримечательности не всегда могут служить абсолютными ориентирами: Эйфелева башня может указывать на Париж с Елисейскими полями, а может на Лас-Вегас или на село Париж в Челябинской области. В отсутствие подобных ориентиров люди полагаются на такие признаки как язык дорожных знаков, разметку, окружающую флору; опираясь на знания о внешнем мире для уточнения оценки местоположения. Традиционные системы компьютерного зрения часто не обладают подобными сведениями, полагаясь лишь на то что можно почерпнуть из тестовой выборки.

Для решения задачи геолокации применялись:

- расстояния между изображениями вычисляемые при помощи глобальных дескрипторов изображений. Рассматривалось в 2008 году в работе IM2GPS Хейса и Эфроса из Карнеги Меллон [1]. Рассматривается далее более подробно.
- Дополнение данными спутниковой съемки [4].
- Распознавание ориентиров [5].
- Распознавание формы городского горизонта Skyline2GPS [6]

1.2 Изучение и сравнительный анализ алгоритмов Выделения признаков изображений с целью выбора подхода к задаче

Для задач обработки изображений используется множество различных методов. Перечислим некоторые из них.

1.2.1 Глобальные дескрипторы

Глобальные дескрипторы описывают изображение в целом и представляют его в виде векторов признаков. Обычно каждая точка вносит вклад в значение дескриптора. При поиске по коллекции цветных изображений для человека одной из наиболее значимых характеристик является цвет. К тому же он инвариантен относительно расположения объектов и размера изображения, что упрощает его анализ. Самое распространенное представление цвета - это цветовая гистограмма




Рис. 1.1 – Гистограмма цветов и квантованная картинка.

Квантование проведено с помощью 10-NN кластеризации

[7] (гистограмма распределения цветов). Подход заключается в том, что цветовое пространство разбивается на промежутки и для каждого промежутка вычисляется доля пикселей из данного промежутка. Процесс разбиения цветового пространства на ограниченное количество цветовых диапазонов называется квантованием. Сложность данного подхода заключается в построении такого разбиения, чтобы цвета из одного диапазона были плохо различимы человеком, а цвета из разных диапазонов, наоборот, различались. Пример гистограммы с квантованием в цветовом пространстве RGB изображен на Рисунке 1.1.

В простейшем случае, и в частности в данном примере, не учитывается пространственное расположение цветов на изображении. Решением является разбиение изображения на фиксированные блоки и вычисление цветовой гистограммы отдельно для каждого блока. Однако в данном решении возникает проблема в подборе размеров блоков. Еще одним решением проблемы учета пространственного расположения цветов является модификация классической цветовой гистограммы HistSP. Главная идея данного метода заключается в том, что для каждого ненулевого элемента гистограммы вычисляется центр масс пикселей соответствующего цвета, его координаты сохраняются в числе элементов вектора признаков.

Альтернативная модель представления цвета изображения – это цветовые моменты, предложенные Stricker M., Orengo M. [8]. Авторы рассматривают распределения отдельных цветовых каналов как части трехмерного распределения. Вводится пять фиксированных областей: центральная область в виде эллипса и четыре боковые области. Для каждой области вычисляется математическое ожидание по каждому из цветовых каналов и попарные ковариации распределений каналов. Для каждого из пикселей вычисляется его степень принадлежности к области: чем ближе к границе области, тем меньше степень принадлежности к ней. Это значение регулирует вклад цвета соответствующего пикселя в общую оценку распределения цвета области. Еще одной значимой характеристикой изображения является текстура. Она описывает структуру объектов на

изображении, и определяется по распределению уровня яркости изображения.

Одним из наиболее известных представлений текстурных характеристик изображения являются матрицы смежности (матрицы совместного распределения яркости на изображении - Grey Level Co-occurrence Matrices, GLCM) [9]. Матрица смежности зависит от разницы яркости в соседних пикселях. По ней можно вычислить значения различных статистических показателей, например, таких как энтропия (степень неоднородности), контраст, показатель однородности, показатель гладкости и др. Еще одними из известных текстурных признаков являются признаки Тамуры [8], которые были выделены с учетом особенностей зрительного восприятия человека. Они включают в себя зернистость, контрастность, направленность, линейность, регулярность и грубость. Из них были определены три наиболее подходящих при решении задачи поиска изображений – это зернистость, контрастность и направленность. Если собрать эти значения в одно изображение, в котором red, green, blue каналы будут заменены на зернистость, контрастность и направленность соответственно, то из полученного изображения можно вычислить 3d текстурную гистограмму. Если будем разбивать на промежутки зернистость, контрастность и направленность, то получим 3d гистограмму, аналогичную цветовой 3d гистограмме на Рисунке 1, только с другими осями координат. Для рассмотрения текстуры изображения в различных масштабах, можно использовать вейвлет-анализ, который заключается в разложении сигнала по базисным функциям. Базисные функции (вейвлеты) строятся на основе порождающего вейвлета с помощью сдвига и масштабирования. Берется исходное изображение и строится первая проекция сигнала (свертка с первой базисной функцией), потом вычисляется разность исходного сигнала с полученным и строится вторая проекция этой разности (свертка со второй базисной функцией), и т.д. Причем, каждая базисная функция является сдвигом предыдущей, растянутой в 2^n раз (n характеризует масштаб). Таким образом, в итоге получаем грубую версию изображения. Такие базисные функции обычно называют фильтрами.

Одними из эффективных и используемых фильтров являются фильтры Габора, ICA-фильтры (Independent Component Analysis, ICA [10]). ICA-фильтры получены путем анализа обучающего множества изображений. Данные фильтры являются локальными и подобны фильтрам Габора, однако в отличие от них носят естественный характер и отражают основные направления текстуры изображений, по которым они строились. Также проводились исследования, показывающие, что способ построения ICA-фильтров схож с процессом зрительного обучения человека. Еще одним важным признаком для сравнения изображений является форма объектов. Простейшими признаками являются центр тяжести фигур, площадь, направление главной оси и т.д. Существуют и более сложные методы, представляющие фигуры более детально, их можно разделить на два класса:

- внешнее представление, основанное на информации о контуре фигуры – дескрипторы границ, к ним относятся разные виды сигнатур, дескрипторы Фурье, вейвлет-дескрипторы, цепные коды и т.д.;
- внутреннее представление, основанное на информации о фигуре в целом – дескрипторы областей, к ним относятся, например, инварианты моментов и т.д.

1.2.2 Локальные дескрипторы

Локальные дескрипторы представляют собой вектора признаков, построенные по отдельным фрагментам изображения. То есть они не описывают все изображение, а содержат информацию только о выбранных некоторым способом фрагментах. Самыми известными локальными дескрипторами являются SIFT [10] (Scale Invariant Feature Transform), SURF [11] (Speeded Up Robust Features), PCA-SIFT [12] (PCA – Principal Component Analysis) и т.д. Метод SIFT (Scale Invariant Feature Transform) обнаруживает и описывает локальные особенности изображения. Получаемые с помощью него признаки инвариантны относительно масштаба и поворота, устойчивы к ряду аффинных преобразований, шуму, изменению в освещении. Данный алгоритм можно разделить на две части: определение «точек интереса» (key points, points of interest, salient points) и построение дескрипторов окрестностей данных точек. Существует несколько способов определения точек интереса. Алгоритм, предложенный в рамках SIFT, один из самых известных. Он заключается в использовании пирамиды Гаусса, которая строится для изображения.

Далее изображения приводятся к одному размеру, и вычисляется их разность (DoG, difference-of-Gaussian images). Причем в качестве кандидатов точек интереса выбираются только те пиксели, которые сильно отличаются от остальных, это делается, например, путем сравнения каждого пикселя изображения с несколькими соседними данного масштаба, с несколькими соответствующими соседями в большем и меньшем масштабе. Далее для каждой такой точки интереса вычисляется локальный дескриптор, характеризующий направление градиентов в пикселях некоторой окрестности. Главным минусом SIFT дескрипторов является их высокая размерность и большое количество на изображении. PCA-SIFT [12] (PCA, Principal Component Analysis – анализ главных компонент) дескриптор – одна из вариаций SIFT, в которой уменьшается размерность дескриптора с помощью анализа главных компонент. Это достигается с помощью нахождения пространства собственных векторов, на которое впоследствии проецируются вектора признаков.

Альтернативным подходом является SURF [12] (Speeded Up Robust Features), который в несколько раз быстрее SIFT. В данном подходе для ускорения поиска точек интереса используются интегральные изображения [15]. Значение в каждой точке интегрального изображения вычисляется

как сумма значения в данной точке и значений всех точек, которые находятся выше и левее данной. С помощью интегральных изображений за константное время вычисляются так называемые прямоугольные фильтры [16], которые состоят из нескольких прямоугольных областей. SURF в несколько раз быстрее SIFT, менее чувствителен к шуму, к повороту, но чувствителен к изменению освещения или угла, под которым был сделан снимок. Глобальные и локальные дескрипторы обычно используются для решения разных задач. Глобальные дескрипторы в основном применяются для решения задачи общего поиска изображений по содержанию, то есть для поиска по запросу-образцу визуально и семантически похожих изображений. В данном случае важно все изображение в целом, а не отдельные его области, поэтому для решения данной задачи подходят глобальные дескрипторы, характеризующие все изображение. Локальные дескрипторы обычно применяются для решения задачи поиска нечетких дубликатов. Дубликатами считаются изображения одной и той же сцены или объекта, сделанные в разных условиях или разного качества, в частности, изображения одной и той же сцены в разном масштабе или снятые с разных точек, с различием в освещении или с незначительными изменениями фона. При решении данной задачи важно обнаружить сходство отдельных частей изображений, для данных целей обычно применяются локальные дескрипторы, описывающие особенности областей изображений.

Все вышеописанные локальные дескрипторы используют общую парадигму, заключающуюся в нахождении точек интереса и построении для каждой из них дескриптора, описывающего ее окрестность. Принципиально другой подход описан в работе [13]. Он основан на свойстве повторяемости (самоподобии) фрагментов на изображении, то есть на наблюдении, что небольшие фрагменты изображения имеют свойство повторяться на нем в том же или другом масштабе. Информация о такой повторяемости в пределах некоторой области изображения формирует так называемую геометрическую разметку. С помощью данной геометрической разметки формируются самоподобные локальные дескрипторы. Причем, даже если изображения имеют разную текстуру, цвет и др., но их геометрические разметки похожи, то дескрипторы тоже будут похожи. Эксперименты, проведенные авторами работы, показали применимость данных дескрипторов для решения задач распознавания объектов и поиска фрагментов в коллекциях изображений и видео без предварительного обучения. Также стоит заметить, что большинство других локальных дескрипторов строятся только для точек интереса и, следовательно, не описывают все изображение в целом. Самоподобные локальные дескрипторы изначально строятся для каждой точки изображения, после чего производится фильтрация, даже после которой самоподобные дескрипторы образуют более плотное множество по сравнению с другими описанными локальными дескрипторами.

1.2.3 Глубокие сверточные нейросети (ГСНС)

Часто для выделения значимых признаков в изображениях требуются экспертные знания, а потому их непросто описать алгоритмически. Функции выделения в ГСНС автоматически формируют изображения для определенных областей, не используя никакие функции обработки отличительных признаков. Благодаря этому процессу ГСНС пригодны для анализа изображений:

ГСНС обучают сети с множеством слоев.

- Несколько слоев работают вместе для формирования улучшенного пространства отличительных признаков.
- Начальные слои изучают первостепенные признаки (цвет, края и пр.).
- Дальнейшие слои изучают признаки более высокого порядка (в соответствии с входным набором данных).
- Наконец, признаки итогового слоя подаются в слои классификации.

Теперь осталось только формально определить, что же такое свертка и как устроены слои сверточной сети. Свертка — это всего лишь линейное преобразование входных данных особого вида. Если x^l — карта признаков в слое под номером l , то результат двумерной свертки с ядром размера $2d + 1$ и матрицей весов W размера $(2d + 1) \times (2d + 1)$ на следующем слое будет таким:

$$y_{i,j}^l = \sum_{-d \leq a, b \leq d} W_{a,b} x_{i+a, j+b}^l,$$

где $y_{i,j}^l$ — результат свертки в i, j -том пикселе на уровне l , а $x_{i,j}^l$ — её вход (выход предыдущего слоя). Иначе говоря, чтобы получить компоненту (i, j) следующего уровня, мы применяем линейное преобразование к квадратному окну предыдущего уровня, то есть скалярно умножаем пиксели из окна на вектор свертки.

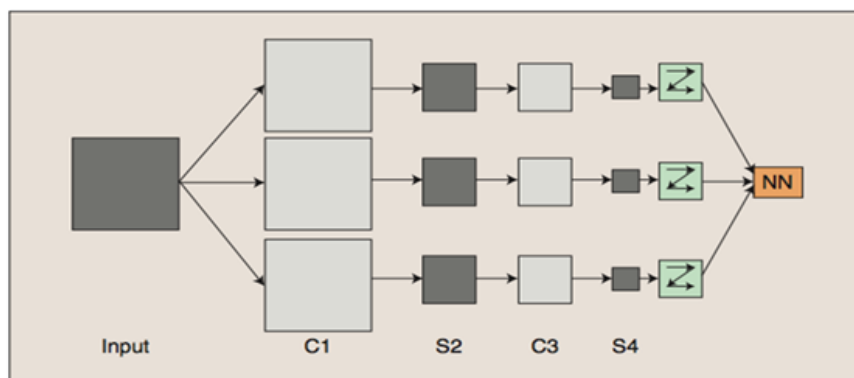


Рис. 1.2 – Пример архитектуры свёрточной сети. Слои C — свертки, слои S — пулы и выборки.

Определение 1 (Свертка). Сверточные слои состоят из прямоугольной сети нейронов. Веса при

этом одинаковы для каждого нейрона в сверточном слое. Веса сверточного слоя определяют фильтр свертки.

Определение 2 (Опрос). Опрашивающий слой берет небольшие прямоугольные блоки из сверточного слоя и проводит подвыборку, чтобы сделать из этого блока один выход.

1.3 Анализ алгоритмов пространственного разбиения поверхности земли для решения задачи классификации

Подразумевается что мы рассматриваем задачу геолокации как задачу классификации областей Земной поверхности, а не как задачу регрессии координат. Это позволяет работать с выходом модели как с гистограммой распределения вероятности нахождения фотографии в точках поверхности земли. Достоинство такого подхода схоже с задачей классификации изображений, когда правильный класс может быть не первым, а например одним из 5 наиболее вероятных догадок, что может быть использовано. Существует множество способов проекции 2-сферы на плоскость, однако у каждого из них есть свои недостатки: Проекция Меркатора, представитель класса равноугольных проекций, не сохраняет пропорций (Гренландия значительно меньше Африки), Равновеликие проекции не сохраняют форму объектов, что менее критично но также нежелательно. Поэтому интересным представляется следующее решение проблемы — использование не проекции на плоскость, а разбиения поверхности на области при помощи проекции поверхности на грани куба, См рис 1.3. Очевидно что если просто взять максимально плотное разбиение поверхности ничего путного не выйдет: будет слишком много пустых областей и областей с недостаточным числом примеров.

1.4 Существующие решения задачи геолокации по изображениям

Описанные выше в пункте по работы [3] представляют собой state-of-the-art на текущий момент, однако автору не удалось обнаружить в свободном доступе ПО, демонстрирующее функциональность описанных методов.

1.4.1 ПО для работы с алгоритмами глубокого обучения

```
caffe2
tensorflow
keras
pytorch
roll your own
```




Рис. 1.3 – S-2 Проекция в двухмерном случае. Стороны квадрата рекурсивно разделяются и проектируются на окружность

1.5 Анализ возможностей применения подхода transfer learning к проблеме геолокации с помощью глубокого обучения

1.6 Выводы

Подразумевается что разрабатываемая система действует автономно и не обладает дополнительной информацией о мире кроме информации о пространственной плотности объектов тестовой выборки.

Тут пишем выводы по результатам анализа: что и с какой целью было проанализировано, какие выводы из этого сделаны, как они повлияли (должны повлиять) на дальнейший ход работы. Результаты анализа приводятся по пунктно, основные выводы из проделанного анализа. Например:

1. Выполнен сравнительный анализ различных алгоритмов формирования признаков изображений (Локальные и Глобальные дескрипторы, Свёрточные нейронные сети) с точки зрения применимости к решению задачи визуальной локализации. Наиболее подходящей по признаку наилучших результатов признана система на основе свёрточной нейронной сети.
2. Был рассмотрен подход Transfer Learning и показана целесообразность его использования для решения поставленной задачи.
3. В качестве основной библиотеки для глубокого обучения была выбрана библиотека `caffe2`[?] из-за наличия предобученных моделей и простоты интеграции

1.7 Постановка задачи УИР

Цель данного исследования — обзор современных алгоритмов глубокого обучения и применение их к задаче геолокации по серии изображений, а также создание ПО, демонстрирующего их работу на тестовых примерах.

Для достижения поставленной цели требуется

- изучить подробно применение современных алгоритмов глубокого обучения к задачам Компьютерного Зрения,
- изучить современные нейросетевые методы работы с данными в виде последовательностей,
- изучить методы визуализации картографических данных,
- разработать способ генерации исходных данных для задачи визуальной локализации,
- спроектировать систему генерации признаков изображений для последующей классификации местоположений,
- разработать методы классификации вышеописанных векторов признаков,
- описать и разработать методы оценки точности классификации и провести сравнительный анализ различных подходов к задачам классификации и генерации признаков.

2. Разработка моделей и алгоритмов ...

В этой главе описываются разработанные/модифицированные модели/методы/ алгоритмы, или/и описывается применение известных стандартных методов. Также, в конце главы обычно приводится общая архитектура программной системы, вытекающая из описанной теории. Приведенные ниже заголовки подразделов так же весьма примерные и сильно зависят от особенностей конкретной работы.

2.1 Формальная постановка задачи геолокации по серии изображений

Задача геолокации (визуальной локализации) в данном исследовании ставится как задача классификации изображений местности в соответствующие им области земной поверхности. Более формально, пусть:

- K — число ячеек в которых могли быть сделаны фотографии,
- N — число фотографий,
- m_i — число фотографий в i -том альбоме,
- Q — число альбомов,
- X — множество фотографий.
- Y — множество ячеек,
- $s2(\gamma)$ — сопоставление GPS координатам γ ячейке из Y . Для обучающей выборки известны значения $s2^{-1}$, то есть отображения $y \rightarrow \gamma$

ячейка — область земной поверхности, выделенная например с помощью S2 разбиения,

фотография — тензор $l \times q \times 3$ действительных чисел, l, q — ширина и высота соответственно¹,

альбом — упорядоченный набор из m_i фотографий объединённых по признаку нахождения в одной ячейке, K, N, Q определяются обучающей выборкой.

Обучающая выборка — множество пар «фотография — ячейка», $\mathbf{X} = \{(X_j, y_j) | j = 1..N\}$, можно объединённые в альбомы по m_j штук.

Требуется разработать:

- алгоритм, $\mathcal{F} : X \rightarrow Y$ который будет сопоставлять элементу x_j класс \hat{y}_j наиболее близкий к тому которым x_j обладает в реальности, с набором параметров W_1
- алгоритм $\mathcal{G} : [X] \rightarrow Y$, где $[x]$ — список x , решающий эту задачу для альбома, \mathcal{G} обладает набором параметров W_2

¹индексы фотографии для простоты опущены

Обучение \mathcal{F} и \mathcal{G} состоит в подборе наборов параметров W_1 и W_2 . Следует отметить что целесообразно использовать для реализации \mathcal{G} параметры \mathcal{F} , а значит W_2 — суть W_1 и параметры, специфичные для обработки последовательностей. Оптимальные значения параметров W_1 и W_2 зависят от обучающей выборки.

Таким образом можно рассматривать \mathcal{F} и \mathcal{G} как отображение обучающей выборки в множество функций, отображающих в Y .

Следует также отметить что частота разбиения поверхности может быть различной, а значит для каждого масштаба возможно обучать различные версии \mathcal{F} и \mathcal{G} .

Для простоты будем считать что перед подачей на вход алгоритмам изображения масштабируются и обрезаются если требуется. Процесс масштабирования будет описан ниже.

2.2 Выбор/разработка методов оценки точности работы алгоритмов геолокации

Для получения нижней оценки на точность алгоритма можно рассматривать в качестве ошибки предсказания расстояние от центра ячейки (\hat{y}) до реальных GPS координат фотографии $s2^{-1}(y)$, рассчитанное по поверхности земли $d(a, b)$.

Тогда ошибкой для выборки будет

$$E = \frac{1}{K} \sum_{i=1}^K d(y_i, C(\hat{y}_i))$$

Для обучения будем использовать скользящий контроль.

2.3 Модификация существующих решений в области для работы с серией изображений

Хотя разрабатываемая архитектура способна локализовать большое разнообразие изображений, многие изображения неоднозначны или не предоставляют достаточно информации, которая позволила бы их локализовать. Однако мы можем использовать тот факт, что фотографии естественным образом происходят в последовательности, например, альбомы, место съёмки которых часто значительно скоррелировано. Интуитивно, если мы с уверенностью можем локализовать некоторые из фотографий в альбоме, мы можем использовать эту информацию, чтобы локализовать фотографии с неопределённым местоположением. Фотографии в альбоме — это последовательность, которая требует модели, которая запоминает состояние предыдущего примера, при рассмотрении текущего примера. Поэтому целесообразно использовать (LSTM) [14] для этой задачи. Теперь мы рассмотрим, как решить проблему прогнозирования геолокации последовательности фотографий с использованием LSTM.

2.3.1 Сети LSTM

Долгая краткосрочная память (Long short-term memory; LSTM) – особая разновидность архитектуры рекуррентных нейронных сетей, способная к обучению долговременным зависимостям. Они были представлены Зеппом Хохрайтер и Юргеном Шмидхубером (Jürgen Schmidhuber)[14] в 1997 году, а затем усовершенствованы и популярно изложены в работах многих других исследователей. Они прекрасно решают целый ряд разнообразных задач и в настоящее время широко используются.

LSTM разработаны специально, чтобы избежать проблемы долговременной зависимости. Поэтому запоминание информации на долгие периоды времени легко реализуется данной архитектурой.

Опишем основную операцию генератора паттенов на основе LSTM[15]: Блок LSTM имеет механизмы, позволяющие «запоминать» информацию для расширенного количества временных шагов. Мы используем блок LSTM со следующими преобразованиями, которые отображают входы для выходов по блокам в последовательных слоях и последовательных временных шагах:

$$\begin{aligned}f_t &= \sigma_g(W_f x_t + U_f h_{t-1} + b_f) \\i_t &= \sigma_g(W_i x_t + U_i h_{t-1} + b_i) \\o_t &= \sigma_g(W_o x_t + U_o h_{t-1} + b_o) \\c_t &= f_t \circ c_{t-1} + i_t \circ \sigma_c(W_c x_t + U_c h_{t-1} + b_c) \\h_t &= o_t \circ \sigma_h(c_t)\end{aligned}$$

где \circ - оператор поэлементного умножения, и две функции активации:

$$\begin{aligned}\sigma(\mathbf{x}_i) &= \frac{1}{1 + e^{-\mathbf{x}_i}} \\ \tanh(\mathbf{x}_i) &= \frac{1 - e^{-2\mathbf{x}_i}}{1 + e^{-2\mathbf{x}_i}}\end{aligned}$$

Переменные:

- x_t — входной вектор,
- h_t — выходной вектор,
- c_t — вектор состояний,
- W , U и b — матрицы параметров и вектор,
- f_t , i_t и o_t — векторы вентилей,
- f_t — вектор вентиля забывания, вес запоминания старой информации,
- i_t — вектор входного вентиля, вес получения новой информации,
- o_t — вектор выходного вентиля, кандидат на выход.




Рис. 2.1 – Повторяющийся модуль в LSTM сети

В приведенных выше преобразованиях ячейка памяти c_t хранит «долгосрочную» память в векторной форме. Другими словами, информация накапливается и кодируется до тех пор, пока временной интервал t не будет сохранен в c_t и будет передаваться только через один и тот же уровень на разных временных шагах. Учитывая входы c_t и h_t , вход и «забывающий» элемент f_t помогут ячейке памяти решить, как перезаписать или сохранить информацию в памяти. Выходной шлюз далее позволяет блоку LSTM решить, как получить информацию о памяти для генерации текущего состояния h_t , которое передается как на следующий уровень текущего временного шага, так и на следующий шаг времени текущего уровня. Такие решения принимаются с использованием параметров скрытого слоя W и b с разными индексами: эти параметры будут выведены на этапе обучения сети.

2.3.2 Архитектура Модели

Основная структура нашей модели такова: учитывая изображение, мы извлекаем вектор признаков изображения (до слоя SoftMax) в PlaNet. Этот вектор подается в блок LSTM. Выходной вектор LSTM затем подается в слой SoftMax, который выполняет классификацию в ячейки S2. Мы подаём альбом в модель в хронологическом порядке. В генерации признаков мы переиспользуем параметры модели для одиночного изображения. Во время обучения мы сохраняем их фиксированными и только обучать параметры LSTM и слой SoftMax.

Проблема с этой простой моделью LSTM заключается в том, что многие альбомы содержат вначале несколько изображений, которые не содержат полезной визуальной информации. Благодаря своей однонаправленности эта модель не может исправить неверные прогнозы, что происходит в начале последовательности после наблюдения фото с уверенным местоположением. По этой причине мы сейчас оценим модель, в которой LSTM использует множество фотографий от

альбома, прежде чем сделать свое первое предсказание. Смещение метки. Идея этой модели состоит в том, чтобы сдвинуть поиск поисков, что вывод отложен на несколько временных шагов. Основная мотивация этой идеи состоит в том, что модель может накапливать информацию из нескольких изображений в последовательность перед предсказаниями. Тем не менее, мы обнаружили, что использование смещений не улучшает локализацию (Таблица 4, LSTM off1, LSTM off2). Предположим, что из-за ввода входного изображения на выходные метки становится более сложным, затрудняя прогнозирование для всех фотографий, улучшая прогнозы только для конечности количество фотографий. Более того, этот подход не решает проблему повсеместно: например, если мы компенсируем метку на 2 шага, но первое изображение Фертильность возникает только после 3 шагов, прогноз для первого изображения, вероятно, все еще будет неправильным. Чтобы исправить это, теперь мы сидером, которые определяют их прогнозы на всех изображениях в последовательности, а не только предыдущие. Повторяющиеся последовательности. Сначала мы оцениваем модель, которая обученный по последовательностям включая два экземпляра одной и той же последовательности. для эта модель, мы принимаем только прогнозы для изображений из вторая половина последовательности (т. е. повторяющаяся часть).

При времени вывода, передавая последовательность в модель в первый раз можно рассматривать как стадию кодирования, где LSTM создает внутреннее состояние на основе изображений. Второй проход представляет собой этап декодирования, где на каждом изображении, LSTM делает прогноз на основе его состояния, аренда изображение. Результаты показывают, что этот подход превосходит однопроходные LSTM, достигающие 7,8% относительное улучшение на уровне улицы, ценой двоякого увеличение времени вывода. Однако, В результате мы обнаружили проблему с этим подходом: если в начале последовательности, они, как правило, привязаны к последнему катюна в последовательности, поскольку модель учится полагаться на его предыдущее предсказание. Поэтому прогнозы с конца последовательности переносятся в начало. Двухнаправленный LSTM. Известная нейронная сеть аг- архитектуры, которая обуславливает прогнозы в целом последовательности являются двухнаправленными LSTM (BLSTM). Эта модель можно рассматривать как конкатенацию двух моделей LSTM, где первая выполняет передний проход, а вторая выполняет обратный проход по последовательности. Двухнаправленные LSTM не могут быть обучены с помощью обратного распространения во времени с усечением и, следовательно, для LSTM до полной длины последовательности. Чтобы уменьшить вычислительную стоимость обучения, нам пришлось ограничить продолжительность последовательности до 25 изображений. Это приводит к снижению общей точности, поскольку более длинные альбомы обычно дают большую точность чем короткие. Поскольку наши эксперименты по этим данным не сопоставимы с предыдущими, мы также оценили повторяющуюся модель LSTM на усеченных последовательностях до 25 изоб-

ражений. Как показывают результаты BLSTM явно превосходят повторные LSTM (Относительное улучшение на уровне улицы на 16,6%). Однако, потому что они не подходят для длинных последовательностей, повторяющиеся модель может быть предпочтительнее на практике.

2.4 Разработка метода геолокации по серии изображений используя выбранные/разработанные выше алгоритмы/методы

2.5 Выводы

Необходимо перечислить, какие теоретические результаты были получены с указанием степени новизны. Например: «Была разработана такая-то модель. Она представляет собой адаптированную версию модели X , в которой уравнение Z заменено на уравнение Z' ». Еще пример: «Была предложена такая-то архитектура, она отличается от типовой в том-то и том-то. Это позволяет избежать таких-то проблем.». При этом не следует заниматься «высасыванием из пальца»: «Поставленная задача является типовой; для ее решения применены стандартные средства (перечислить, какие).».

3. Инженерная часть

В этой главе описывается, что и как было спроектировано. При необходимости, описывается использованная методика проектирования. Сюда же относится описание внешних и внутренних программных интерфейсов, а также форматы и структуры входных и выходных данных.

3.1 Использование методики «такой-то» для проектирования программных систем «такого-то типа»

3.2 Проектирование системы геолокации по серии изображений

...

3.3 Архитектура подсистемы генерации признаков

...

3.4 Архитектура подсистемы классификации

...

3.5 Проектирование протокола взаимодействия подсистем классификации и генерации признаков

...

3.6 Выводы

Следует перечислить, какие инженерные результаты были получены, а именно: какие программные системы, подсистемы или модули были спроектированы. Следует не только назвать полученные архитектуры, но и отметить их отличительные особенности.

4. Реализация и экспериментальная проверка ...

В этой главе описывается, что и как было запрограммировано, отлажено, протестировано, и что в результате получилось. Большинство работ должны содержать приведенные ниже разделы. Но нужно учитывать, что точный состав этой главы, как и других глав, зависит от специфики работы.

Фрагменты программного кода в тексте необходимо выделять при помощи команды `\verb`.

Многострочные листинги должны оформляться при помощи пакета `listingsutf8`. Пример:

```
# let s x y z = x z (y z);;
val s : ('a -> 'b -> 'c) -> ('a -> 'b) -> 'a -> 'c = <fun>
# let k x y = x;;
val k : 'a -> 'b -> 'a = <fun>
# let i = s k k;;
val i : '_a -> '_a = <fun>
```

Листинг 4.1 иллюстрирует использование выносных листингов. Листинг 4.2 показывает пример включения внешнего файла в качестве листинга, в данном случае — выносного.

4.1 Выбор инструментальных средств

В этом разделе обосновывается выбор инструментальных средств; одним из критериев выбора могут быть какие-либо требования к разрабатываемой системе, и если этих требований много, они могут быть выделены в отдельный раздел, или же в приложение. Этот пункт не пишется, если в аналитической главе был раздел, посвященный сравнительному анализу и выбору инструментальных средств.

4.2 Состав и структура реализованного программного обеспечения

Нужно охарактеризовать реализованное ПО: является ли оно настольной программой для Windows, или веб-приложением в форме сайта/веб-сервиса, или модулем/подключаемой библиотекой, или Также нужно перечислить, из чего оно состоит: какие исполняемые файлы и их назначение, конфигурационные файлы, файлы баз данных, требования к программному и аппаратному окружению, и т.п.

Если реализованное приложение достаточно обширно, этот раздел может быть разделен на несколько: один с общим описанием, и по одному на подсистемы самого верхнего уровня.

```
List myList = new List();
Element myElement = new Element();
myList.Append(myElement);
```

Листинг 4.1 – Выносной листинг

```
object HelloWorld {  
  def main(args: Array[String]) {  
    println("Hello, world!")  
  }  
}
```

Листинг 4.2 – Листинг из файла HelloWorld.scala

4.3 Результаты экспериментов

4.3.1 Эксперимент с 1 изображением

4.3.2 Эксперимент с альбомом

Мы сравниваем эту модель с моделью и базовый уровень, который просто усредняет прогнозы single-imagePlaNet всех изображений в альбоме и назначает среднее для всех изображений. Усреднение в альбомах ($\mathcal{G} = \mathbb{E}[\mathcal{F}(X)]$) уже дают значительное улучшение по сравнению с одним изображением PlaNet (45,7% на уровне улиц), поскольку у него больше вмятины предсказания к неоднозначным изображениям. Однако, LSTM модель явно превосходит технику усреднения (50,5% относительное улучшение уровня улицы). Визуальный контроль результатов показали, что за достоверностью следуют несколько изображений с более низким местоположением уверенности, модель LSTM присваивает низкий уровень доверия изображения, расположенные вблизи изображения с высокой степенью достоверности в то время как \mathcal{F} может «прыгать» (менять предположение о расположении альбома), модель LSTM имеет тенденцию прогнозировать близкие местоположения, кроме случаев когда есть убедительные доказательства изменения местоположения. LSTM модель работает лучше усреднения из-за того что оно присваивает всем изображениям в альбоме одинаковые уровни значимости и не может производить точные прогнозы для альбомов которые включают разные местоположения (например, альбомы поездок).

4.4 Разработка тестовых примеров

Описываются наиболее характерные тестовые примеры, для прогона на интеграционных тестах. (Да, использование unit-тестирования — это почти всегда хорошо, основное исключение составляют работы, в которых используемый инструментарий по какой-либо причине в принципе исключает такую возможность. Например, что-нибудь вроде Mathematica.)

В этом же разделе могут приводиться и результаты тестирования, включая таблицы и графики. Результаты тестирования могут быть вынесены в отдельный раздел, если много текстового материала и/или использована (не совсем) стандартная методика тестирования (описание которой также нужно привести).

4.5 Результаты тестирования и примеры работы системы

Нужно помнить, что пользователем может быть не только «менеджер» или «человек в белом халате», но и другой программист. Последнее относится, в первую очередь, к реализованным библиотекам. Для «обычных» приложений нередко бывают пользователи нескольких категорий — например, обычный пользователь и администратор. Для каждой категории нужно описать, как выполняются основные функции, предпочтительно, с помощью серии скрин-шотов. Однако считается плохим тоном вставлять длинную вереницу из скрин-шотов: если их много, большую часть нужно выносить в приложение. Для *этого* раздела нормальной является плотность скрин-шотов из расчета: 1 страница скрин-шотов на 1-2 страницы текста.

Замечание. В ПЗ (как УИРа, так и ВКР) следует избегать ситуаций, когда значительную часть основного содержания составляют страницы с иллюстрациями и таблицами, особенно, если такие страницы следуют подряд. В основном тексте следует оставлять лишь самые основные таблицы и рисунки, а остальное — выносить в приложение.

4.6 Сравнение реализованного программного обеспечения с существующими аналогами

В сравнении должно быть отражено, чем полученное ПО выгодно (и невыгодно) отличается от прочих ближайших аналогов. Практика показывает, что аналоги есть всегда. А если нет аналогов, значит есть частичные решения, которые реализуют какие-то части функционала вашей системы. Тут тоже может быть относительно много таблиц и графиков.

4.7 Выводы

Следует перечислить, какие практические результаты были получены, а именно: какое программное или иное обеспечение было создано. В число результатов могут входить, например, методики тестирования, тестовые примеры (для проверки корректности/оценки характеристик тех или иных алгоритмов) и др. По каждому результату следует сделать вывод, насколько он отличается от известных промышленных аналогов и исследовательских прототипов.

Заключение

В заключении в тезисной форме необходимо отразить результаты работы:

- аналитические (что изучено/проанализировано);
- теоретические;
- инженерные (что спроектировано);
- практические (что реализовано/внедрено).

Примерная формула такая: по каждому указанному пункту приводится по 3-5 результатов, каждый результат излагается в объеме до 5 фраз или предложений.

Также есть смысл привести предполагаемые направления для будущей работы.

Общий объем заключения не должен превышать 1,5 страниц (1 страницы для УИРов).

Список литературы

1. Hays James, Efros Alexei A. IM2GPS: estimating geographic information from a single image // Computer Vision and Pattern Recognition, 2008. CVPR 2008. IEEE Conference on / IEEE. — 2008. — P. 1–8.
2. Geometric reasoning under uncertainty for map-based localization / William B Thompson, Carolyn M Valiquette, Bonnie H Bennett, Karen T Sutherland // Spatial Cognition and Computation. — 1999. — Vol. 1, no. 3. — P. 291–321.
3. Weyand Tobias, Kostrikov Ilya, Philbin James. Planet-photo geolocation with convolutional neural networks // European Conference on Computer Vision / Springer. — 2016. — P. 37–55.
4. Lin Tsung-Yi, Belongie Serge, Hays James. Cross-view image geolocalization // Computer Vision and Pattern Recognition (CVPR), 2013 IEEE Conference on / IEEE. — 2013. — P. 891–898.
5. Retrieving landmark and non-landmark images from community photo collections / Yannis Avrithis, Yannis Kalantidis, Giorgos Tolas, Evaggelos Spyrou // Proceedings of the 18th ACM international conference on Multimedia / ACM. — 2010. — P. 153–162.
6. Skyline2gps: Localization in urban canyons using omni-skylines / Srikumar Ramalingam, Sofien Bouaziz, Peter Sturm, Matthew Brand // Intelligent Robots and Systems (IROS), 2010 IEEE/RSJ International Conference on / IEEE. — 2010. — P. 3816–3823.
7. Color histogram. — 2018. — Jan. — Page Version ID: 821304796. online; accessed: https://en.wikipedia.org/w/index.php?title=Color_histogram&oldid=821304796 (online; accessed: 2018-04-16).
8. Stricker Markus, Dimai Alexander. Spectral covariance and fuzzy regions for image indexing // Machine vision and applications. — 1997. — Vol. 10, no. 2. — P. 66–73.
9. Haralick Robert M, Shanmugam Karthikeyan et al. Textural features for image classification // IEEE Transactions on systems, man, and cybernetics. — 1973. — no. 6. — P. 610–621.
10. Lowe David G. Object recognition from local scale-invariant features // Computer vision, 1999. The proceedings of the seventh IEEE international conference on / Ieee. — Vol. 2. — 1999. — P. 1150–1157.

11. Bay Herbert, Tuytelaars Tinne, Van Gool Luc. Surf: Speeded up robust features // European conference on computer vision / Springer. — 2006. — P. 404–417.
12. Ke Yan, Sukthankar Rahul. PCA-SIFT: A more distinctive representation for local image descriptors // Computer Vision and Pattern Recognition, 2004. CVPR 2004. Proceedings of the 2004 IEEE Computer Society Conference on / IEEE. — Vol. 2. — 2004. — P. II–II.
13. Shechtman Eli, Irani Michal. Matching local self-similarities across images and videos // Computer Vision and Pattern Recognition, 2007. CVPR'07. IEEE Conference on / IEEE. — 2007. — P. 1–8.
14. Hochreiter Sepp, Schmidhuber Jürgen. Long short-term memory // Neural computation. — 1997. — Vol. 9, no. 8. — P. 1735–1780.
15. Gers Felix A, Schmidhuber Jürgen, Cummins Fred. Learning to forget: Continual prediction with LSTM. — 1999.